HENJAI

เห็นใจ

รายงานฉบับสมบูรณ์

โครงการผู้ช่วยบรรยายภาพด้วยปัญญาประดิษฐ์
ที่เข้าใจอารมณ์และบริบทสำหรับผู้พิการทางสายตา

Emotion & Context-Aware AI Vision Assistant

ผู้จัดทำ

นายกิตติพงศ์ สมสอาด
นายชินพัฒน์ ขุนเจริญ
นายเรข์ณพัศ สุวรรณปริสุทธิ์

ทีม Rushhour
นิสิตชั้นปีที่ 2 หลักสูตรวิศวกรรมคอมพิวเตอร์และเทคโนโลยีดิจิทัล (CEDT)
ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย

บทสรุปผู้บริหาร

HENJAI หรือ “เห็นใจ” เป็นโครงการพัฒนาต้นแบบผู้ช่วยบรรยายภาพภาษาไทยสำหรับผู้พิการทางสายตา โดยมุ่งให้ผู้ใช้เข้าถึงข้อมูลเกี่ยวกับบุคคล สีหน้าที่สังเกตได้ ท่าทาง สภาพแวดล้อม และสิ่งกีดขวางผ่านเสียงพูด แนวคิดหลักคือการลดภาระจากการตีความภาพด้วยตนเอง และให้ข้อมูลที่สัมพันธ์กับตำแหน่งของผู้ใช้ เช่น “มีเก้าอี้ขวางทางซ้ายของคุณ” แทนการบรรยายองค์ประกอบภาพอย่างกว้าง ๆ

ระบบที่ส่งมอบประกอบด้วยสองรูปแบบ ได้แก่ ต้นแบบบนเครื่องคอมพิวเตอร์ใน `poc/` และต้นแบบเว็บใน `web/` ทั้งสองรูปแบบส่งภาพและบริบทระยะสั้นไปยัง Gemini เพื่อสร้างข้อความบรรยาย ส่วนต้นแบบบนเครื่องมีเส้นทางประมวลผลเพิ่มเติมสำหรับตรวจจับบุคคล ท่าทาง ใบหน้า วัตถุ และประมาณความลึก โดยแยกการเตือนระยะใกล้ออกจากการบรรยายความหมายบนคลาวด์ ระบบเว็บใช้กล้องและเสียงสังเคราะห์ของเบราว์เซอร์ และไม่มีเส้นทางโมเดลในเครื่องเช่นเดียวกับต้นแบบ Python

การตรวจหลักฐานการทดลองเดิมพบผลลัพธ์ 24 รายการ แบ่งเป็นกลุ่มอารมณ์ ท่าทาง สภาพแวดล้อม และฉากที่ไม่เน้นบุคคล กลุ่มละ 6 ภาพ ในผลชุดปัจจุบันประมวลผลสำเร็จ 21 รายการ คิดเป็นร้อยละ 87.5 และมี 3 รายการผิดพลาดจากโควตา API เวลาเฉลี่ยเฉพาะรายการสำเร็จเท่ากับ 2.243 วินาทีต่อภาพ ค่ามัธยฐาน 2.1 วินาที ชุดก่อนปรับปรุงสำเร็จ 24 รายการ และมีเวลาเฉลี่ย 2.842 วินาที ตัวเลขนี้เป็นการสรุปไฟล์ผลเดิม ไม่ใช่การทดลองควบคุมซ้ำในวันจัดทำรายงาน

เมื่อเทียบกลุ่มอารมณ์ 6 ภาพกับป้ายกำกับชั่วคราวจากคำค้นและปรับชื่อคลาสให้สอดคล้องกัน ผลชุดปัจจุบันตรงกัน 5 จาก 6 ภาพ (หากเทียบข้อความคลาสตรงตัวตามสคริปต์เดิมจะได้ 4 จาก 6) อย่างไรก็ตาม คำค้นไม่ใช่คำตอบมาตรฐานที่ผู้ประเมินตรวจภาพจริง และตารางประเมินคุณภาพโดยมนุษย์ยังไม่มีคะแนน จึงยังไม่สามารถสรุปความแม่นยำทั่วไป อัตราการสร้างข้อมูลที่ไม่มีในภาพ ความพึงพอใจ หรือความปลอดภัยในการเดินทางจริงได้

ผลที่ได้แสดงความเป็นไปได้ของการเชื่อมกล้อง การบรรยายภาพ ความจำระยะสั้น และเสียงภาษาไทยเข้าด้วยกัน ขั้นตอนต่อไปคือจัดทำข้อมูลอ้างอิงที่ตรวจสอบโดยมนุษย์ ประเมินกับผู้ใช้เป้าหมายภายใต้การดูแล และวัดเวลาตั้งแต่รับภาพจนผู้ใช้ได้ยินเสียงจริง รายงานนี้ส่งมอบพร้อมคู่มือผู้ใช้ คู่มือพัฒนา ซอร์สต้นฉบับ ชุดซอร์สแบบ ZIP และข้อมูลทดสอบที่ตรวจย้อนกลับได้

กิตติกรรมประกาศ

คณะผู้จัดทำขอขอบคุณคณะวิศวกรรมศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย และหลักสูตรวิศวกรรมคอมพิวเตอร์และเทคโนโลยีดิจิทัล ภาควิชาวิศวกรรมคอมพิวเตอร์ ซึ่งเป็นสังกัดของคณะผู้จัดทำ และขอขอบคุณผู้จัดโครงการฝึกอบรมเทคโนโลยีและปัญญาประดิษฐ์เพื่อพัฒนานวัตกรรมสำหรับผู้พิการ 5 หมวดหมู่ ได้แก่ มหาวิทยาลัยมหิดล ร่วมกับ กสทช. และ สวทช. ที่เปิดโอกาสให้คณะผู้จัดทำนำเสนอแนวคิดและต้นแบบ

ตามข้อมูลกิจกรรมที่คณะผู้จัดทำให้ไว้ ทีมได้รับรางวัลรองชนะเลิศอันดับ 1 จากกิจกรรมเมื่อวันที่ 12–13 กันยายน 2569 ณ โรงแรมรอยัล ริเวอร์ กรุงเทพมหานคร ข้อมูลดังกล่าวเป็นประวัติการเข้าร่วมกิจกรรมของโครงการ และแยกจากผลการประเมินประสิทธิภาพทางเทคนิคที่รายงานในบทที่ 4

ขอขอบคุณผู้เผยแพร่ซอฟต์แวร์ เครื่องมือ แบบจำลอง และภาพทดสอบที่มีแหล่งที่มาในบัญชีข้อมูลของโครงการ องค์ประกอบเหล่านี้ช่วยให้สามารถพัฒนาและตรวจสอบแนวคิดได้อย่างเป็นระบบ การนำทรัพยากรไปใช้ต่อควรคงการให้เครดิตและตรวจเงื่อนไขสิทธิ์ของแต่ละรายการ

คณะผู้จัดทำ ทีม Rushhour

20 ตุลาคม 2569

สารบัญ

บทสรุปผู้บริหาร i

กิตติกรรมประกาศ ii

สารบัญตาราง vi

สารบัญภาพ vii

1 บทนำ 1

1.1 ความเป็นมาและความสำคัญของปัญหา 1

1.2 วัตถุประสงค์ 1

1.3 ขอบเขตการศึกษา 2

1.4 ประโยชน์ที่คาดว่าจะได้รับ 2

1.5 นิยามและการอ่านรายงาน 2

2 เอกสารและงานวิจัยที่เกี่ยวข้อง 3

2.1 การบรรยายภาพด้วยโมเดลภาษาภาพ 3

2.2 การตรวจจับวัตถุและการประมาณท่าทาง 3

2.3 การวิเคราะห์ใบหน้าและการจำแนกสีหน้า 3

2.4 การประมาณความลึกจากภาพเดียว 4

2.5 กล้องและเสียงบนเว็บ 4

2.6 แนวทางการเข้าถึงและตำแหน่งของโครงการ 4

3 วิธีดำเนินการ 6

3.1 ขั้นตอนและแหล่งข้อมูลสำหรับจัดทำรายงาน 6

3.2 การวิเคราะห์ความต้องการ 6

3.3 สถาปัตยกรรมระบบ 7

3.4 กระบวนการทาง AI บนคลาวด์ 8
3.4.1 การเตรียมภาพและเลือกโหมด 8
3.4.2 คำสั่งและสัญญาข้อมูล 8
3.4.3 ความจำ การกันซ้ำ และการอ่านเอกสาร 9
3.5 กระบวนการประมวลผลในเครื่อง 9
3.6 การออกแบบการทดสอบและการวัดผล 10

4 ผลการดำเนินงาน 11
4.1 ผลลัพธ์ด้านระบบ 11
4.2 ผลการประมวลผลภาพที่บันทึกไว้ 11
4.3 การวิเคราะห์กลุ่มอารมณ์รายภาพ 13
4.4 คุณภาพคำบรรยายและผลที่ยังประเมินไม่ได้ 13
4.5 ข้อจำกัดและการตรวจย้อนกลับ 14

5 สรุปและข้อเสนอแนะ 15
5.1 สรุปผลการศึกษา 15
5.2 การนำไปใช้ประโยชน์ 15
5.3 ข้อเสนอแนะตามลำดับความสำคัญ 15
5.4 เกณฑ์สำหรับการประเมินรอบถัดไป 16

บรรณานุกรม 17

A บัญชีไฟล์ส่งมอบและข้อมูลทดสอบ 18
A.1 รายการส่งมอบ 18
A.2 โครงสร้างข้อมูลทดสอบและสิทธิ์ 19
A.3 บัญชีรายภาพ 19

B ตัวอย่างข้อมูลและแนวทางตรวจซ้ำ 21
B.1 ตัวอย่างภาพทดสอบและสิ่งที่ระบบตอบ 21
B.2 ข้อควรระวังในการรันทดสอบซ้ำ 22

B.3 ข้อมูลที่ยังต้องเติมก่อนรับรองการใช้งานจริง 22

สารบัญตาราง

1.1 คำสำคัญที่ใช้ในรายงาน 2

2.1 ความสัมพันธ์ระหว่างองค์ความรู้กับองค์ประกอบของ HENJAI 5

3.1 ความต้องการและวิธีรองรับในต้นแบบ 6

3.2 โหมดคำสั่งและค่าควบคุมการเปลี่ยนภาพ 8

3.3 ข้อมูลผลลัพธ์ของการวิเคราะห์ภาพ 9

4.1 สถานะความสามารถและขอบเขตหลักฐาน 11

4.2 สถิติจากผลเดิม แสดงเวลาเฉพาะรายการสำเร็จเป็นวินาที 11

4.3 ความครอบคลุมและเวลาเฉลี่ยแยกกลุ่มในผลชุดปัจจุบัน 12

4.4 ผลกลุ่มอารมณ์เทียบกับป้ายกำกับชั่วคราวจากคำค้น 13

A.1 เอกสารและไฟล์ที่จัดเตรียมเพื่อส่งมอบ 18

A.2 เวลาที่ระบบใช้ตอบต่อภาพ (วินาที) แยกตามกลุ่มภาพ 20

B.1 ภาพตัวอย่าง คำบรรยายจากระบบ และเครดิตภาพ 21

สารบัญภาพ

3.1 สถาปัตยกรรมต้นแบบ Python ตามองค์ประกอบในโค้ดปัจจุบัน 7

3.2 การไหลของข้อมูลในต้นแบบเว็บ ซึ่งไม่มีชุดโมเดลสายเร็วของ Python 7

4.1 เวลาเฉลี่ยเฉพาะคำขอสำเร็จจากผลเดิม ตัวหารสองชุดต่างกัน จึงไม่ใช่ข้อสรุปเชิงเหตุและผล 12

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

การรับรู้สิ่งแวดล้อมผ่านการมองเห็นครอบคลุมทั้งตำแหน่งวัตถุ การเปลี่ยนแปลงของสถานการณ์ และสัญญาณทางสังคม ผู้พิการทางสายตาอาจเข้าถึงข้อมูลเหล่านี้ได้ไม่ครบถ้วนจากเสียงแวดล้อมเพียงอย่างเดียว ตัวอย่าง เช่น การทราบว่ามีคนอยู่ตรงหน้ายังไม่เพียงพอต่อการเข้าใจว่าอีกฝ่ายกำลังหันมาพูดคุย โบกมือ หรือแสดงสีหน้าที่ควรระมัดระวัง ขณะเดียวกัน การบรรยายภาพทุกส่วนอย่างยืดยาวอาจรบกวนการฟังเสียงรอบตัวและทำให้ข้อมูลสำคัญมาถึงช้า

โครงการจึงเสนอผู้ช่วยที่ใช้กล้องเป็นช่องทางรับข้อมูลและแปลงผลวิเคราะห์เป็นเสียงภาษาไทย โดยให้ความสำคัญกับสิ่งที่เกี่ยวข้องกับผู้ใช้ ณ ขณะนั้น การออกแบบต้องพิจารณาทั้งคุณภาพคำบรรยาย ความกระชับ ความหน่วง การพูดซ้ำ และภาระการควบคุมหน้าจอ ไม่ใช่เพียงจำนวนวัตถุที่โมเดลระบุได้

เอกสารแนวคิดและต้นแบบเดิมใช้ชื่อ Emotion & Context-Aware AI Vision Assistant และพัฒนาเป็น HENJAI แนวทางที่ปรากฏในโค้ดมีการเปลี่ยนจากต้นแบบบรรยายภาพแบบเดี่ยวไปสู่ระบบที่แบ่งงานระหว่างการตรวจเหตุการณ์ในเครื่องกับการสร้างความหมายบนคลาวด์ เพื่อให้การตอบสนองเหมาะกับลักษณะงานมากขึ้น

1.2 วัตถุประสงค์

1. พัฒนาต้นแบบรับภาพจากกล้อง วิเคราะห์บุคคล สีหน้า ท่าทาง และบริบท แล้วส่งผลเป็นคำบรรยายและเสียงภาษาไทย
2. ออกแบบคำบรรยายที่สั้นและสัมพันธ์กับตำแหน่งผู้ใช้ โดยให้ความสำคัญกับสิ่งที่ต้องระวังและสิ่งที่เปลี่ยนไป
3. ลดการเรียกบริการเมื่อภาพนิ่ง และลดการพูดซ้ำด้วยประวัติคำบรรยายระยะสั้น
4. ศึกษาความเป็นไปได้ของการแยกงานประมวลผลในเครื่องและบนคลาวด์ พร้อมสรุปผลทดสอบและข้อจำกัดจากหลักฐานที่มี
5. จัดทำเอกสารและไฟล์สำหรับตรวจสอบ ใช้งาน และพัฒนาต่ออย่างเป็นระบบ

1.3 ขอบเขตการศึกษา

ขอบเขตซอฟต์แวร์ประกอบด้วยต้นแบบ Python/Flask สำหรับเครื่องคอมพิวเตอร์ และต้นแบบเว็บที่ใช้ JavaScript กับฟังก์ชันฝั่งเซิร์ฟเวอร์ การวิเคราะห์ความหมายของภาพใช้โมเดลที่มีอยู่ผ่าน API โดยไม่ได้ฝึกโมเดลภาษาภาพหลักขึ้นใหม่ ส่วนการประมวลผลในเครื่องอาศัยโมเดลสำเร็จรูปและกฎที่เขียนในโครงการ

ขอบเขต ข้อมูล ประเมิน อ้างอิง `poc/eval/results.json`, `results_before.json`, `score.csv` และ `manifest.json` ภาพที่มีอยู่จริงมี 25 ภาพ แต่ผลการทดลองที่บันทึกไว้ครอบคลุม 24 ภาพแรกเท่านั้น ภาพ `emotion_6.jpg` จึงนับเป็นข้อมูลเพิ่มเติมที่ยังไม่มีผลในชุดรายงานนี้ ไม่ขยายตัวหารของผลเดิมเป็น 25

การศึกษานี้ยังไม่ครอบคลุมการรับรองการใช้งานด้านความปลอดภัย การนำทางอิสระ การทดสอบภาคสนามกับผู้พิการทางสายตาอย่างเป็นระบบ หรือการรับรองการเข้าถึงตามมาตรฐานใด การอ่านเอกสารเป็นความสามารถที่ปรากฏในคำสั่งและโค้ดปัจจุบัน แต่ไม่มีชุดทดสอบ OCR ที่เป็นหลักฐานผลสำเร็จ

1.4 ประโยชน์ที่คาดว่าจะได้รับ

ผู้ใช้เป้าหมายอาจเข้าถึงข้อมูลของบุคคลและสภาพแวดล้อมผ่านเสียงได้สะดวกขึ้น ผู้ดูแลและผู้สาธิตมีต้นแบบสำหรับทดลองรูปแบบปฏิสัมพันธ์ ส่วนผู้พัฒนาได้ฐานซอฟต์แวร์และข้อมูลที่สามารถตรวจซ้ำได้ ประโยชน์ต่อผู้ใช้จริงยังเป็นสมมติฐานของการออกแบบที่ต้องประเมินต่อ ไม่ใช่ผลที่ยืนยันจากการทดลองในชุดนี้

1.5 นิยามและการอ่านรายงาน

ตารางที่ 1.1: คำสำคัญที่ใช้ในรายงาน

คำ	ความหมายในโครงการ
คำบรรยายบริบท	ข้อความที่เชื่อมสิ่งที่เห็นกับสถานการณ์และตำแหน่งของผู้ใช้
สีหน้าหรืออารมณ์	การตีความสิ่งที่สังเกตได้จากภาพ ไม่ใช่การยืนยันสภาวะภายในบุคคล
สายเร็ว	เส้นทางโมเดลในเครื่องของต้นแบบ Python สำหรับข้อมูลใกล้ตัว
สายช้า	เส้นทาง Gemini ที่สร้างคำบรรยายและปรับปรุงความจำ
ความจำระยะสั้น	คำบรรยายล่าสุดและสรุปบริบทภายใน session
หลักฐานผลเดิม	ไฟล์ผลที่บันทึกไว้ก่อนจัดทำรายงาน ไม่ใช่ผลรันใหม่

บทที่ 2

เอกสารและงานวิจัยที่เกี่ยวข้อง

2.1 การบรรยายภาพด้วยโมเดลภาษาภาพ

โมเดลภาษาภาพรับข้อมูลภาพร่วมกับคำสั่งข้อความ เพื่อสร้างคำอธิบายที่ตอบโจทย์การใช้งาน เอกสาร Gemini API อธิบายการส่งภาพเป็นข้อมูล inline และการถามตอบเกี่ยวกับภาพ [1] โครงการประยุกต์ความสามารถนี้โดยส่งภาพ JPEG ร่วมกับคำสั่งภาษาไทยและประวัติบริบท แล้วขอผลลัพธ์รูปแบบ JSON แทนการนำข้อความอิสระไปใช้โดยตรง

ข้อได้เปรียบคือการรวมข้อมูลบุคคล สถานที่ และข้อความให้อยู่ในคำบรรยายเดียวโดยไม่ต้องฝึกโมเดลแยกทุกงาน ข้อแลกเปลี่ยนของการออกแบบในโครงการคือการพึ่งพาเครือข่าย โควตา และรูปแบบคำตอบจากบริการภายนอก ข้อผิดพลาดดังกล่าวปรากฏจริงในไฟล์ผลทดสอบ จึงต้องแยกความสำเร็จของคำขอออกจากความถูกต้องของเนื้อหา

2.2 การตรวจจับวัตถุและการประมาณท่าทาง

เอกสาร Ultralytics อธิบายงาน pose estimation ว่าให้ตำแหน่งจุดสำคัญของร่างกาย [2] โครงการใช้ YOLO11n-Pose สำหรับจุดข้อต่อ และ YOLO11n สำหรับกรอบวัตถุ โดยแปลงผลบางส่วนเป็นกฎท่าทาง เช่น ยกมือหรือกอดอก การแปลงกฎเป็นความหมายทางสังคมเป็นการตัดสินใจของโครงการ ไม่ใช่คุณสมบัติที่ผ่านการรับรองของตัวตรวจจับ

ใน `fast.read` โค้ดพิจารณาบุคคลที่มีความสูงของกรอบมากที่สุด และใช้ค่าความเชื่อมั่นของจุดข้อต่อก่อนตีความท่าทาง การเลือกบุคคลด้วยขนาดกรอบเป็นวิธีเชิงประมาณ จึงอาจเลือกคนที่ไม่ใช่คู่สนทนาที่ผู้ใช้ตั้งใจสนใจในฉากหลายคน

2.3 การวิเคราะห์ใบหน้าและการจำแนกสีหน้า

MediaPipe Face Landmarker ให้จุดอ้างอิงใบหน้าและค่าสัญญาณ blendshape [3] โครงการใช้ผลนี้ประกอบการประมาณทิศทางการมองและสัญญาณใบหน้าในเส้นทางประมวลผลในเครื่อง ส่วนสคริปต์เปรียบเทียบเดิมใช้โมเดล `trpakov/vit-face-expression` [5] ในงานจำแนกสีหน้าหลังตัดบริเวณใบหน้าหรือศีรษะ

ควรแยกการทดลอง FER ดังกล่าวออกจากเส้นทางปัจจุบันของระบบ เพราะ `fast.py` ใช้ MediaPipe และความลึก ไม่ได้เรียก ViT classifier ตัวเดียวกับ benchmark เดิม การนำค่าความเร็ว FER จาก README

ไปอ้างเป็นเวลาของระบบปัจจุบันทั้งหมดจึงไม่ตรงกับองค์ประกอบที่ทำงานจริง

2.4 การประมาณความลึกจากภาพเดียว

งาน Depth Anything V2 เสนอแบบจำลองประมาณความลึกจากภาพเดียว [4] โครงการเลือกใช้ checkpoint แบบ metric indoor ผ่าน Transformers และอ่านค่า `predicted_depth` เพื่อคำนวณระยะในแถบล่างของภาพ การใช้ค่าทำนายเป็นระยะทางเชิงกายภาพต้องตรวจสอบกับกล้องและสภาพแวดล้อมที่ใช้งานจริง

ในโครงการ พื้นที่แนวตั้งร้อยละ 50–95 ของภาพถูกแบ่งแนวนอนเป็นสามส่วน ใช้ค่ามัธยฐานของแต่ละส่วนแทนระยะทางด้านซ้าย ตรงหน้า และขวา แล้วเลือกส่วนที่ระยะน้อยที่สุด วิธีนี้เป็นกฎสรุปเชิงพื้นที่ ไม่ได้พิสูจน์ว่าตำแหน่งนั้นตรงกับเส้นทางเดินจริงของผู้ใช้ หรือครอบคลุมสิ่งกีดขวางทุกขนาด

2.5 กล้องและเสียงบนเว็บ

เอกสาร API ของเบราว์เซอร์ระบุว่า `getUserMedia` ใช้รับสื่อจากอุปกรณ์ภายใต้สิทธิ์ของผู้ใช้และบริบทที่ปลอดภัย [6] โครงการใช้ API นี้กับกล้องด้านหลังเป็นตัวเลือกที่ต้องการ และย่อภาพก่อนส่งไปยังเซิร์ฟเวอร์ สำหรับเสียง เว็บใช้ `speechSynthesis` ซึ่งมีรายการเสียงตามระบบที่ใช้งาน [7] ดังนั้นการมีเสียงภาษาไทยและพฤติกรรมการเริ่มเล่นเสียงขึ้นกับเบราว์เซอร์และอุปกรณ์

2.6 แนวทางการเข้าถึงและตำแหน่งของโครงการ

WCAG 2.2 เป็นกรอบแนวทางการเข้าถึงเนื้อหาเว็บ [8] โครงการนำหลักการลดภาระการควบคุมและให้ข้อมูลผ่านเสียงมาใช้กับหน้าจอปุ่มขนาดใหญ่ แต่ยังไม่มีผลตรวจความสอดคล้องกับ WCAG จึงควรใช้กรอบดังกล่าวเป็นแนวทางประเมินต่อไป

ตารางที่ 2.1: ความสัมพันธ์ระหว่างองค์ความรู้กับองค์ประกอบของ HENJAI

องค์ความรู้	การใช้ในระบบ	ข้อจำกัดที่ต้องทดสอบ
โมเดลภาษาภาพ	บรรยายบริบทเป็นภาษาไทย	ข้อมูลเกินภาพ ความหน่วง โควตา
Object/ Pose detection	ตำแหน่งวัตถุและข้อต่อ	การบังกัน แสง และมุมกล้อง
Face landmarks	สัญญาณใบหน้าและการมอง	หน้าขนาดเล็กหรือหันข้าง
Monocular depth	ประมาณความใกล้ในสามทิศ	ความคลาดเคลื่อนระยะจริง
Browser media/ TTS	รับภาพและสื่อสารด้วยเสียง	สิทธิ์กล้องและเสียงไทย

ช่องว่างที่โครงการมุ่งแก้คือการรวมข้อมูลหลายชนิดให้เป็นคำบรรยายภาษาไทยที่สัมพันธ์กับผู้ใช้ และลดข้อความซ้ำระหว่างการใช้งานต่อเนื่อง ความแตกต่างนี้เป็นการออกแบบปฏิสัมพันธ์และการเชื่อมระบบ ไม่ใช่ข้ออ้างว่าเสนอโมเดลพื้นฐานใหม่หรือทำได้ดีกว่างานอื่นจากการทดลองเปรียบเทียบมาตรฐาน

บทที่ 3

วิธีดำเนินการ

3.1 ขั้นตอนและแหล่งข้อมูลสำหรับจัดทำรายงาน

กระบวนการประกอบด้วยการรวบรวมความต้องการจากเอกสารแนวคิด การออกแบบคำบรรยายและหน้าจอ การเชื่อมกล้องกับบริการ AI การเพิ่มการตรวจภาพเปลี่ยนและความจำ จากนั้นจัดทำชุดภาพทดสอบและเก็บผล การจัดทำรายงานฉบับนี้ตรวจเทียบเอกสาร `handoff.md`, `pitch.md`, `slide.md` กับโค้ดปัจจุบันและไฟล์ผล โดยให้โค้ดกับผลที่บันทึกไว้เป็นหลักเมื่อเอกสารเก่าระบุไม่ตรงกัน

ไม่ได้เก็บภาพจากกล้องใหม่ ไม่ได้เรียกโมเดลคลาวด์ซ้ำ และไม่ได้ทดลองกับผู้ใช้เป้าหมายเพิ่มเติมในรอบการจัดทำเอกสาร ดังนั้นคำว่า “ผลการดำเนินงาน” ในรายงานครอบคลุมซอฟต์แวร์ที่มีอยู่และการวิเคราะห์หลักฐานเดิม ไม่ใช้แทนผลรับรองระบบพร้อมใช้งานภาคสนาม

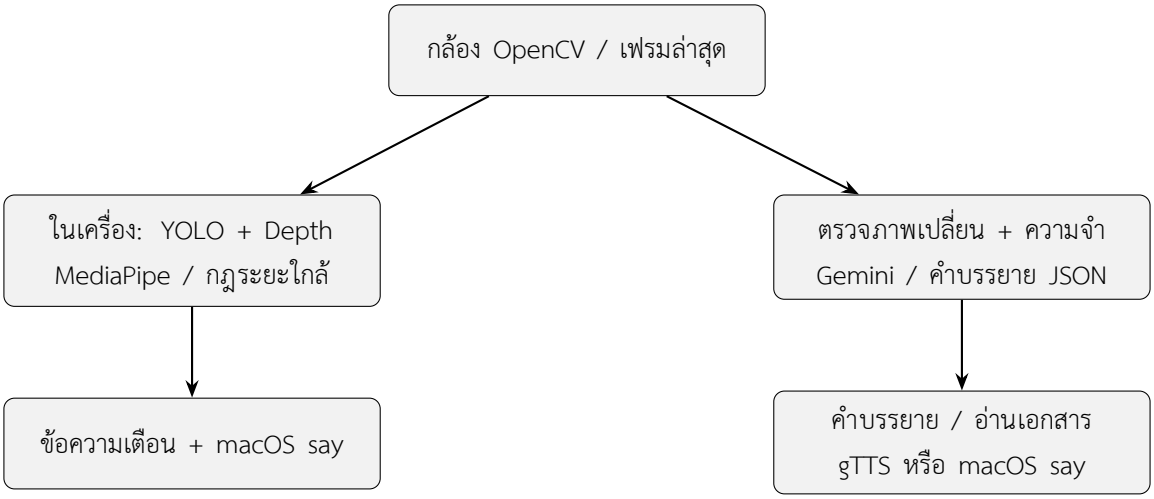
3.2 การวิเคราะห์ความต้องการ

ตารางที่ 3.1: ความต้องการและวิธีรองรับในต้นแบบ

รหัส	ความต้องการ	วิธีรองรับที่พบในซอร์ส
FR-01	รับภาพจากสภาพแวดล้อม	OpenCV ใน Python; getUserMedia บนเว็บ
FR-02	บรรยายบุคคลและบริบทเป็นภาษาไทย	Gemini พร้อม SYSTEM_PROMPT
FR-03	แจ้งข้อมูลที่สัมพันธ์กับผู้ใช้	กฎคำบรรยายเน้นทิศและสิ่งต้องระวัง
FR-04	ฟังเสียงคำบรรยาย	gTTS/macOS หรือ Browser TTS
FR-05	ลดการพูดเรื่องเดิม	recent 5 ประโยค สรุป 600 ตัวอักษร
FR-06	ลดคำขอเมื่อภาพนิ่ง	คะแนนความแตกต่างของภาพย่อ
FR-07	รองรับการอ่านเอกสาร	reading.is_document และ reading.text
FR-08	ตรวจข้อมูลระยะใกล้ในเครื่อง	YOLO/Depth/MediaPipe เฉพาะ Python

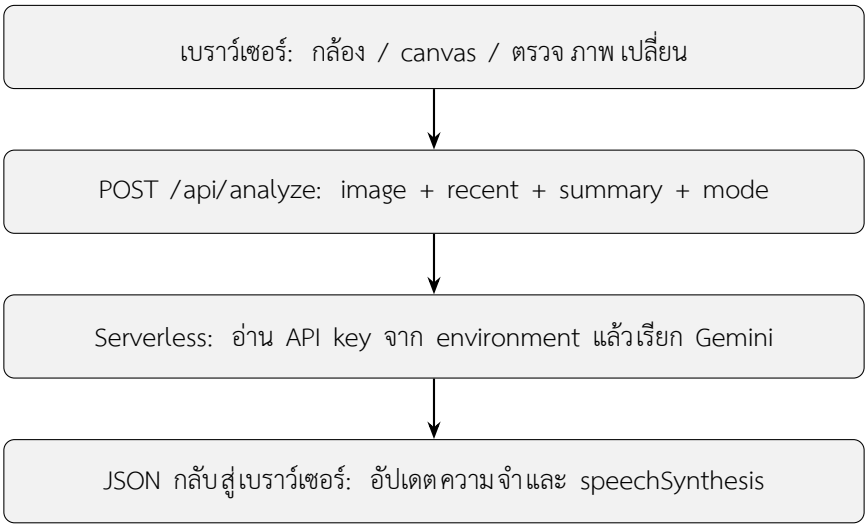
ความต้องการด้านคุณภาพประกอบด้วยการเริ่มและหยุดได้ง่าย การหลีกเลี่ยงเสียงทับกัน การแสดงสถานะผิดพลาด การจำกัดบริบทที่ส่งไป และการไม่เปิดเผย API key ต่อเบราว์เซอร์ อย่างไรก็ตาม การมีโค้ดรองรับความต้องการไม่ได้แปลว่าผ่านเกณฑ์คุณภาพแล้ว จำเป็นต้องตรวจประสิทธิผลในสถานการณ์ใช้งานจริงอีกครั้ง

3.3 สถาปัตยกรรมระบบ



ภาพที่ 3.1: สถาปัตยกรรมต้นแบบ Python ตามองค์ประกอบในโค้ดปัจจุบัน

คลาส `Session` ใน `poc/core.py` แยกการรับภาพ การวิเคราะห์คลาวด์ และเส้นทางประมวลผลในเครื่องออกจากกัน ข้อมูลเฟรมล่าสุดถูกอ่านภายใต้ lock ส่วน Flask ส่งหน้าจอ สถานะ และวิดีโอ MJPEG ให้เบราว์เซอร์ การตั้งค่าระหว่าง session อยู่ในหน่วยความจำ ยกเว้นค่ากล้องที่เลือกซึ่งมีไฟล์บันทึกเฉพาะเครื่อง



ภาพที่ 3.2: การไหลของข้อมูลในต้นแบบเว็บ ซึ่งไม่มีชุดโมเดลสายเร็วของ Python

ระบบเว็บไม่เก็บความจำ session เป็นฐานข้อมูลฝั่งเซิร์ฟเวอร์ แต่ส่ง `recent[]` และ `summary` มา

กับคำขอแต่ละครั้ง คำว่าไม่เก็บ state ในฟังก์ชันนี้ไม่ได้รับประกันว่าผู้ให้บริการภายนอกหรือระบบบันทึกของแพลตฟอร์มไม่มีการเก็บข้อมูล ผู้รับช่วงต้องกำหนดนโยบายการจัดการข้อมูลก่อนเปิดใช้งานจริง

3.4 กระบวนการทาง AI บนคลาวด์

3.4.1 การเตรียมภาพและเลือกโหมด

ต้นแบบ Python แปลงภาพเป็น RGB และย่อความกว้างเมื่อเกิน 768 พิกเซล รักษาสัดส่วน แล้วบันทึกเป็น JPEG คุณภาพ 80 เว็บใช้ canvas กว้าง 768 พิกเซลและ JPEG คุณภาพ 0.8 ภาพสำหรับตรวจการเปลี่ยนแปลงถูกลดเหลือ 64 คูณ 36 พิกเซลในระดับเทา คะแนนความเปลี่ยนแปลงนิยามเป็น

$$D_t = \frac{1}{255N} \sum_{i=1}^{N} |G_t(i) - G_{t-1}(i)|, \qquad N = 64 \times 36. \tag{3.1}$$

ค่าต่ำหมายถึงภาพใกล้เคียงกัน ค่าสูงหมายถึงความต่างมาก แต่การเคลื่อนของกล้องก็ทำให้ค่าสูงได้โดยไม่มีวัตถุใหม่ ดังนั้นคะแนนนี้เป็นตัวควบคุมการเรียก AI ไม่ใช่ตัวตรวจอันตรายโดยตรง

ตารางที่ 3.2: โหมดคำสั่งและค่าควบคุมการเปลี่ยนภาพ

โหมด	การทำงาน	เงื่อนไขหลัก
first	บรรยายภาพรวมครั้งแรก	ยังไม่มีผลสำเร็จก่อนหน้า
skip	ข้ามการเรียกบริการ	ภาพเปลี่ยนน้อยกว่า still
delta	บอกเฉพาะสิ่งเปลี่ยน	มากกว่า still แต่น้อยกว่า scene
scene	บรรยายสถานที่ใหม่	มากกว่าหรือเท่ากับ scene
alert	เริ่มจากสิ่งต้องระวัง	มากกว่าหรือเท่ากับ alert

เว็บกำหนด still เท่ากับ 0.02, scene เท่ากับ 0.18 และ alert เท่ากับ 0.45 ส่วน Python คำนวณเกณฑ์จาก noise กล้อง ด้วยตัวคูณ 2.5, 9 และ 22 ตามลำดับ ตัวอย่าง noise 0.02 ให้เกณฑ์ 0.05, 0.18 และ 0.44 การสอบเทียบใช้ค่ามัธยฐานความต่างของเฟรมช่วงเริ่มต้น 40 ค่า จึงควรตั้งกล้องให้นิ่งในช่วงเริ่ม session

3.4.2 คำสั่งและสัญญาข้อมูล

คำสั่งหลักระบุให้ตอบ JSON และใช้คลาสอารมณ์จำกัด ได้แก่ happy, sad, angry, fear, surprised, disgust, neutral และ no_person พร้อมคำอธิบายภาษาไทย กฎสำคัญคือห้ามเปลี่ยนสีหน้าลบเป็นคำบรรยายบวก หากไม่ชัดให้ลดความเชื่อมั่น และให้กล่าวถึงผู้ใช้โดยตรง

ตารางที่ 3.3: ข้อมูลผลลัพธ์ของการวิเคราะห์ภาพ

ฟิลด์	หน้าที่
`narrative_th`	คำบรรยายสั้นภาษาไทย โดยคำสั่งตั้งเป้าไม่เกิน 20 คำ
`emotion`	label, confidence และ detail_th ของสีหน้าที่ตีความ
`body_language`	รายละเอียดท่าทางที่สังเกตได้
`environment`	ฉาก วัตถุ และข้อความเกี่ยวกับสิ่งต้องระวัง
`reading`	สถานะเอกสารและข้อความที่อ่านได้
`memory_th`	สรุปบริบทเพื่อใช้รอบถัดไป

ค่าการเรียกในซอร์สใช้ temperature 0.4 และจำกัดผลลัพธ์ 512 tokens พร้อม timeout 25 วินาที หาก JSON แปลงไม่ได้จะคืนข้อความบางส่วนเป็นคำบรรยาย fallback จึงยังไม่มีการยืนยัน schema อย่างเข้มงวด ข้อกำหนด “ไม่เกิน 20 คำ” เป็นข้อกำหนดใน prompt และยังไม่มีตัวนับคำภาษาไทยบังคับหลังรับคำตอบ

3.4.3 ความจำ การกันซ้ำ และการอ่านเอกสาร

Python เก็บข้อความล่าสุด 5 ประโยค และตรวจความคล้ายด้วย `difflib.SequenceMatcher` ที่เกณฑ์มากกว่า 0.8 เว็บใช้สัดส่วนคำร่วมที่แยกด้วยช่องว่าง ซึ่งต่างจาก Python และอาจมีข้อจำกัดกับภาษาไทยที่ไม่ได้เว้นวรรคทุกคำ สรุปบริบทจากโมเดลถูกตัดให้ไม่เกิน 600 ตัวอักษรก่อนส่งต่อ

เมื่อโมเดลระบุว่าเป็นเอกสาร ระบบใช้ `reading.text` เป็นเนื้อหาสำหรับอ่านต่อจากคำเกริ่น การอ่านเอกสารข้ามการกันข้อความซ้ำแบบคำบรรยายฉาก ข้อจำกัดผลลัพธ์ 512 tokens อาจทำให้เอกสารยาวถูกตัด จึงไม่ควรอ้างว่ารองรับการอ่านเอกสารทุกหน้าได้ครบถ้วนจากโค้ดเพียงอย่างเดียว

3.5 กระบวนการประมวลผลในเครื่อง

เส้นทางปัจจุบันโหลด YOLO11n-Pose, YOLO11n, Depth Anything V2 Metric Indoor Small และ MediaPipe Face Landmarker ใช้ MPS หากมี มิฉะนั้นเลือก CPU โดย MediaPipe ตั้ง delegate เป็น CPU โมเดลความลึกต้องดาวน์โหลดจากผู้ให้บริการเมื่อยังไม่มี cache แม้ขั้นตอน inference จะออกแบบให้ทำในเครื่องก็ตาม

ผลระยะล่างของภาพถูกแปลงเป็น `near_m` และทิศ `near_side` ก่อนเข้า `fast.phrase` กฎเตือนปัจจุบันให้พูดเมื่อระยะต่ำกว่า 0.5 เมตรและสถานะพร้อมเตือน แล้วปิดการเตือนซ้ำจนระยะมากกว่า 0.9 เมตร เกณฑ์ 1.5 เมตรใช้แสดงข้อมูลความใกล้ ไม่ใช่เกณฑ์สั่งพูด อัลกอริทึมยังคำนวณสัญญาณเข้ามาใกล้ แต่ไม่ได้ใช้

สัญญาณนั้นเป็นเงื่อนไขเตือนทุกกรณี

เกณฑ์ระยะเป็นค่าทดลองในโค้ด ไม่ใช่ระยะปลอดภัยที่ผ่านการรับรอง และยังไม่มีหลักฐานสอบเทียบระยะจริงครบหลายสภาพแวดล้อมในชุดส่งมอบ

3.6 การออกแบบการทดสอบและการวัดผล

ภาพ 24 รายการในผลเดิมแบ่งเป็น 4 กลุ่ม กลุ่มละ 6 ภาพ สคริปต์ `eval/run.py` วิเคราะห์แต่ละภาพด้วยโหมด first จึงไม่ใช่การทดสอบความจำต่อเนื่อง สคริปต์บันทึกเวลา label ความเชื่อมั่น คำบรรยาย ข้อควรระวัง และข้อผิดพลาด แล้วเตรียม CSV สำหรับผู้ประเมิน

กำหนดความครอบคลุมเป็นจำนวนรายการสำเร็จหารจำนวนรายการทั้งหมด ส่วนเวลาเฉลี่ยนับเฉพาะรายการที่ไม่มีข้อผิดพลาด เกณฑ์สำหรับผู้ประเมินใน CSV ประกอบด้วย correctness แบบ 0/1, helpfulness แบบ 1–5, conciseness แบบ 1–5 และ hallucination แบบ 0/1 ต้องตรวจภาพจริงก่อนกรอก ไม่อนุมานคะแนนจากชื่อไฟล์หรือคำค้น

การเทียบผลก่อนและหลังควรใช้ชุดภาพคู่กันและแยกข้อผิดพลาดบริการออกจากคุณภาพโมเดล ในรายงานนี้เพิ่มสรุปแบบจับคู่ 21 ภาพที่สำเร็จทั้งสองชุด แต่ไม่ตีความว่าเป็นการทดลองควบคุม เนื่องจากไม่มีบันทึกเงื่อนไขบริการและสภาพเครือข่ายครบถ้วน

บทที่ 4

ผลการดำเนินงาน

4.1 ผลลัพธ์ด้านระบบ

ซอร์สปัจจุบันมีหน้าจอสำหรับผู้ใช้หลัก หน้าจอพัฒนาใน Python การส่งภาพและรับ JSON การใช้ประวัติคำบรรยาย การข้ามภาพนิ่ง และการสร้างเสียงภาษาไทย เส้นทางในเครื่องมีการเตือนระยะชิดตัวตามกฎที่กำหนด ส่วนเว็บใช้การประมวลผลกล้องในเบราว์เซอร์และบริการ Gemini เท่านั้น

ตารางที่ 4.1: สถานะความสามารถและขอบเขตหลักฐาน

ความสามารถ	สิ่งที่พบ	หลักฐานที่ยังขาด
กล้องและคำบรรยาย	มีโค้ดทั้งสองแพลตฟอร์ม	รอบทดสอบกล้องปัจจุบัน
อารมณ์และบริบท	มี JSON ผลเดิม 21 ภาพสำเร็จ	ป้ายกำกับมนุษย์ที่ยืนยันแล้ว
กันพูดซ้ำ/ภาพนิ่ง	มีโค้ดและสคริปต์ทดสอบ	ผลทดสอบการฟังกับผู้ใช้จริง
เตือนระยะในเครื่อง	มีโมเดลและกฎ hysteresis	การสอบเทียบและ hazard recall
อ่านเอกสาร	มี prompt และเส้นทางอ่านเสียง	ชุด OCR และความครบถ้วนข้อความ
การเข้าถึง	มีปุ่มหลักและสถานะเสียง	ผลทดสอบ screen reader/WCAG

4.2 ผลการประมวลผลภาพที่บันทึกไว้

ตารางที่ 4.2: สถิติจากผลเดิม แสดงเวลาเฉพาะรายการสำเร็จเป็นวินาที

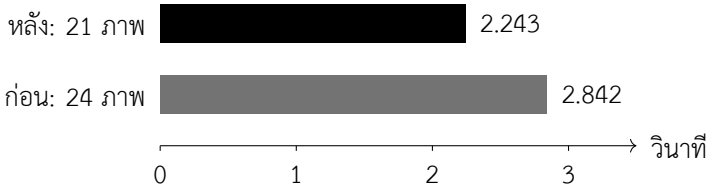
ชุด	ทั้งหมด	สำเร็จ	ผิดพลาด	เฉลี่ย	มัธยฐาน
ก่อนปรับปรุง	24	24	0	2.842	2.75
ชุดปัจจุบัน	24	21	3	2.243	2.10

ตารางที่ 4.3: ความครอบคลุมและเวลาเฉลี่ยแยกกลุ่มในผลชุดปัจจุบัน

กลุ่ม	ทั้งหมด	สำเร็จ	ผิดพลาด	วินาที
อารมณ์	6	6	0	2.083
ท่าทาง	6	6	0	2.350
สภาพแวดล้อม	6	6	0	2.333
ไม่เน้นบุคคล	6	3	3	2.167

ข้อผิดพลาดทั้งสามรายการในชุดปัจจุบันคือ `nolabel_3.jpg`, `nolabel_4.jpg` และ `nolabel_5.jpg` ซึ่งบันทึก `429RESOURCE_EXHAUSTED` จึงไม่รวมเวลาในค่าเฉลี่ยของรายการสำเร็จ และไม่แปลงรายการเหล่านี้เป็นคำตอบผิดทางความหมายโดยอัตโนมัติ

การเทียบค่าเฉลี่ยรวมก่อนและหลังมีตัวหารต่างกัน จึงเสี่ยงทำให้เข้าใจว่าความเร็วดีขึ้นเพราะการปรับระบบเพียงอย่างเดียว สำหรับภาพ 21 รายการที่สำเร็จทั้งคู่ ค่าเฉลี่ยก่อนเท่ากับ 2.867 วินาที และหลังเท่ากับ 2.243 วินาที แม้จำนวนภาพเท่ากัน แต่เงื่อนไขบริการภายนอกไม่ได้ถูกตรึงไว้ครบ จึงรายงานเป็นข้อสังเกตจาก log เดิม



ภาพที่ 4.1: เวลาเฉลี่ยเฉพาะคำขอสำเร็จจากผลเดิม ตัวหารสองชุดต่างกัน จึงไม่ใช่ข้อสรุปเชิงเหตุและผล

4.3 การวิเคราะห์กลุ่มอารมณ์รายภาพ

ตารางที่ 4.4: ผลกลุ่มอารมณ์เทียบกับป้ายกำกับชั่วคราวจากคำค้น

ภาพ	ป้ายชั่วคราว	ผลชุดปัจจุบัน	การตรงกัน
emotion_0	happy	happy	ตรง
emotion_1	sad	neutral	ไม่ตรง
emotion_2	angry	angry	ตรง
emotion_3	surprise	surprised	ตรงหลังปรับชื่อ
emotion_4	sad	sad	ตรง
emotion_5	happy	happy	ตรง

ตารางข้างต้นนับได้ 5 จาก 6 หลังปรับชื่อ surprise/surprised ให้ตรงกัน ส่วนการเทียบข้อความคลาสตรงตัวกับ `TRUTH` ใน `bench_local.py` จะนับได้ 4 จาก 6 เพราะคลาส surprised ไม่เท่ากับ surprise ทั้งสองตัวเลขวัดคนละวิธี จึงไม่ควรใช้คำว่า “ความแม่นยำ 4/6” โดยไม่ระบุวิธีปรับชื่อ รายงานนี้ใช้ 5/6 เฉพาะการจับคู่คลาสที่ปรับชื่อแล้ว และคง 4/6 ไว้เพื่ออธิบายผลสคริปต์เดิม

กรณี `emotion_1.jpg` คำค้นระบุการร้องไห้ แต่คำบรรยายในผลปัจจุบันตีความว่าอาจกำลังหาวหรือจาม จึงเป็นกรณีที่ควรให้ผู้ประเมินตรวจภาพและบริบทจริงก่อนตัดสิน ส่วน `emotion_2.jpg` เปลี่ยนจากคำตอบเดิม “playful” เป็น “angry” หลังข้อกำหนดคำสั่งถูกปรับให้รายงานสีหน้าลบตรงไปตรงมา อย่างไรก็ตาม ไม่มีบันทึกการทดลองควบคุมที่แยกผลของ prompt ออกจากปัจจัยอื่นทั้งหมด

4.4 คุณภาพคำบรรยายและผลที่ยังประเมินไม่ได้

ใน `score.csv` มี 24 แถว แต่ช่องคะแนนจากมนุษย์ครบทั้งสี่ด้านยังว่างทั้งหมด จึงไม่มีค่าความถูกต้องเชิงเนื้อหา ความเป็นประโยชน์ ความกระชับ หรือ hallucination rate ที่ผ่านการประเมิน ตัวอย่างคำบรรยายที่อ่านดูสมเหตุสมผลไม่เพียงพอจะยืนยันว่าไม่มีข้อมูลเกินภาพ

เอกสาร README เดิมระบุผล FER หลังตัดหัวด้วย YOLO ประมาณ 72 มิลลิวินาที และ YOLO11-Pose ประมาณ 42 มิลลิวินาที แต่ไม่มีตารางผลดิบของ benchmark ดังกล่าวในชุดไฟล์ที่ตรวจพบ อีกทั้งองค์ประกอบสายเร็วปัจจุบันเพิ่มโมเดลความลึกและ MediaPipe จึงไม่นำเวลารวมประมาณ 110 มิลลิวินาทีในเอกสารเก่ามาเป็นผลวัดระบบปัจจุบัน

4.5 ข้อจำกัดและการตรวจย้อนกลับ

ข้อจำกัดสำคัญคือภาพมีจำนวนน้อย การเลือกภาพอาศัยคำค้น ความหมายของป้ายกำกับยังไม่ผ่านผู้ประเมิน และการทดลองเป็นภาพนิ่ง ไม่ใช่วิดีโอต่อเนื่องจากมุมกล้องของผู้ใช้จริง มีความล้มเหลวจากโควตาและไม่มีเวลาตั้งแต่กดเริ่มจนได้ยินเสียงครบวงจร จึงควรตีความผลเป็นหลักฐานความเป็นไปได้ของต้นแบบ

`delivery/data/analysis.json` สรุปจำนวนภาพ รายการผิดพลาด สถิติเวลา และวิธีจับคู่คลาส พร้อม `case_index.csv` สำหรับเชื่อมภาพกับผล ชุดข้อมูลคงไฟล์ผลเดิมโดยไม่เขียนทับและมีบัญชี SHA-256 เพื่อยืนยันความตรงกันของไฟล์ส่งมอบ

บทที่ 5

สรุปและข้อเสนอแนะ

5.1 สรุปผลการศึกษา

โครงการได้ต้นแบบที่เชื่อมการรับภาพ การวิเคราะห์บริบทด้วย AI และการสื่อสารด้วยเสียงภาษาไทย ครอบคลุมทั้งการใช้งานบนเครื่องคอมพิวเตอร์และเว็บ การออกแบบคำบรรยายเน้นผู้ใช้เป็นศูนย์กลาง มีการลดคำขอเมื่อภาพนิ่งและจำบริบทระยะสั้น ส่วนเส้นทางในเครื่องแยกการประเมินระยะใกล้ออกจากการสร้างคำบรรยายบนคลาวด์

หลักฐานผลเดิมยืนยันว่ามีการเรียกวิเคราะห์ภาพสำเร็จ 21 จาก 24 รายการในชุดปัจจุบัน โดยเฉลี่ย 2.243 วินาทีต่อรายการสำเร็จ แต่ยังไม่มีคะแนนคุณภาพจากมนุษย์หรือผลภาคสนามที่เพียงพอ จึงบรรลุการพัฒนาต้นแบบและการรวบรวมหลักฐานขั้นต้น ส่วนเป้าหมายด้านคุณภาพชีวิตและความปลอดภัยต้องศึกษาต่อ

5.2 การนำไปใช้ประโยชน์

สามารถใช้ต้นแบบเป็นสื่อสาธิตการประยุกต์โมเดลภาษาภาพกับเทคโนโลยีช่วยเหลือ ใช้สำรวจรูปแบบคำบรรยายที่ผู้ใช้ต้องการ และใช้เป็นฐานสำหรับพัฒนาชุดประเมินภาษาไทย การสาธิตควรอยู่ในสภาพแวดล้อมควบคุม มีผู้ดูแล และแยกการบรรยายสถานการณ์ออกจากการพึ่งพาระบบเพื่อตัดสินใจเดินทาง

ข้อมูลและคู่มือที่ส่งมอบช่วยให้ผู้รับช่วงตรวจว่าคำบรรยายมาจากไฟล์ใด เปลี่ยนโมเดลหรือ prompt อย่างมีหลักฐาน และวางการทดลองครั้งต่อไปโดยไม่ทำลายผลเดิม ไม่ควรนำผลชนะรางวัลหรือการมีต้นแบบไปใช้แทนหลักฐานความปลอดภัยทางเทคนิค

5.3 ข้อเสนอแนะตามลำดับความสำคัญ

1. จัดทำคำตอบอ้างอิงจากผู้ประเมินอย่างน้อยสองคนต่อภาพ แยกสีหน้าที่เห็นจริงออกจากการคาดเดาอารมณ์ และตกลงแนวทางจัดการภาพกำกวมก่อนสรุปคะแนน
2. วัดความครอบคลุมและความล้มเหลวควบคู่กับคุณภาพ โดยตรึงชุดภาพ เวอร์ชัน prompt โมเดล และค่าการเรียก พร้อมเก็บผลดิบทุกครั้ง
3. วัดเวลา end-to-end รวมการรับภาพ อัปโหลด วิเคราะห์ สังเคราะห์เสียง และการเริ่มได้ยินเสียง แยกค่ากลางกับค่าช่วงช้า และทดสอบเครือข่ายขาดหาย
4. สอบเทียบระยะกับวัตถุจริงหลายชนิด หลายพื้นผิวและระดับแสง รวมกล้องติดศีรษะ ก่อนกำหนดเงื่อนไข

เตือนที่เหมาะสม

5. ทดสอบปุ่มหลักและเสียงกับผู้พิการทางสายตาภายใต้ความยินยอมและการดูแล เก็บข้อมูลว่าคำบรรยายช่วยตัดสินใจจริงหรือสร้างภาระการฟัง
6. ปรับการตรวจ schema และข้อมูลรับเข้า เพิ่มการจำกัดคำขอและควบคุมการเข้าถึงก่อนให้บริการสาธารณะ พร้อมกำหนดนโยบายภาพและเสียง

5.4 เกณฑ์สำหรับการประเมินรอบถัดไป

ก่อนเริ่มควรกำหนดจำนวนกรณี สัดส่วนสถานการณ์ เกณฑ์ความผิดพลาดร้ายแรง และเวลาตอบสนองที่ผู้ใช้ยอมรับร่วมกับผู้เกี่ยวข้อง โดยใช้ผลต้นแบบนี้เป็นฐานตั้งสมมติฐาน ไม่เติมค่าเป้าหมายย้อนหลังให้ดูเหมือนผ่านแล้ว การตัดสินพร้อมใช้งานควรอาศัยผลคุณภาพ ความครอบคลุม และประสบการณ์ผู้ใช้ร่วมกัน

บรรณานุกรม

[1] Google. *Gemini API: Image understanding*. `https://ai.google.dev/gemini-api/docs/image-understanding`. สืบค้น 20 ตุลาคม 2569.

[2] Ultralytics. *Pose Estimation*. `https://docs.ultralytics.com/tasks/pose/`. สืบค้น 20 ตุลาคม 2569.

[3] Google. *Face landmark detection guide*. `https://ai.google.dev/edge/mediapipe/solutions/vision/face_landmarker`. สืบค้น 20 ตุลาคม 2569.

[4] Yang, L., Kang, B., Huang, Z., Zhao, Z., Xu, X., Feng, J., and Zhao, H. (2024). *Depth Anything V2*. arXiv:2406.09414. `https://arxiv.org/abs/2406.09414`.

[5] trpakov. *vit-face-expression: Model card*. `https://huggingface.co/trpakov/vit-face-expression`. สืบค้น 20 ตุลาคม 2569.

[6] MDN Web Docs. *MediaDevices: getUserMedia() method*. `https://developer.mozilla.org/en-US/docs/Web/API/MediaDevices/getUserMedia`. สืบค้น 20 ตุลาคม 2569.

[7] MDN Web Docs. *SpeechSynthesis*. `https://developer.mozilla.org/en-US/docs/Web/API/SpeechSynthesis`. สืบค้น 20 ตุลาคม 2569.

[8] W3C. (2024). *Web Content Accessibility Guidelines (WCAG) 2.2*. `https://www.w3.org/TR/WCAG22/`. สืบค้น 20 ตุลาคม 2569.

[9] ทีม Rushhour. *ซอร์สโค้ด และ บันทึก HENJAI*. `poc/`, `web/`, `handoff.md`, `pitch.md`, `research.md`, `slide.md`. รุ่นซอร์ส `e327cd1`; ตรวจไฟล์ 20 ตุลาคม 2569.

[10] ทีม Rushhour. *หลัก ฐาน การ ทดลอง ภาพ นิ่ง*. `poc/eval/manifest.json`, `results_before.json`, `results.json`, `score.csv`. ไฟล์ผลเดิมของโครงการ; ไม่ได้เรียก API ใหม่ในรอบจัดทำรายงาน.

[11] ข้อมูลจากคณะผู้จัดทำ. *รายชื่อ สังกัด และผลเข้าร่วมโครงการฝึกอบรมเทคโนโลยีและปัญญาประดิษฐ์เพื่อพัฒนานวัตกรรมสำหรับผู้พิการ 5 หมวดหมู่*. กิจกรรม 12–13 กันยายน 2569; ให้ข้อมูลสำหรับรายงาน 20 ตุลาคม 2569.

ภาคผนวก A

บัญชีไฟล์ส่งมอบและข้อมูลทดสอบ

A.1 รายการส่งมอบ

ตารางที่ A.1: เอกสารและไฟล์ที่จัดเตรียมเพื่อส่งมอบ

รายการ	ตำแหน่งภายใน delivery
รายงานฉบับสมบูรณ์	`pdf/report.pdf` และ `latex/report.tex`
คู่มือผู้ใช้	`pdf/user-manual.pdf` และ `latex/user-manual.tex`
คู่มือพัฒนา	`pdf/system-manual.pdf` และ `latex/system-manual.tex`
ไฟล์ต้นฉบับซอฟต์แวร์	`source_files/poc/` และ `source_files/web/` พร้อมไฟล์ประกอบที่จำเป็น
ซอร์สบีบอัด	`henjai-source.zip`
ภาพและข้อมูลทดสอบ	`data/img/`, `data/manifest.json`, ผลเดิม JSON และ CSV
สรุปตรวจสอบข้อมูล	`data/analysis.json`, `data/case_index.csv`, `data/credits.csv`
หลักฐานไฟล์	`SOURCE_MANIFEST.csv`, `DATA_MANIFEST.csv`, `SHA256SUMS.txt`
แนวทางคอมไพล์	`README.md` และ `latex/build.sh`

ชุดต้นฉบับไม่รวม environment ส่วนตัว API key ประวัติ Git cache หรือไฟล์ตั้งค่ากล้องเฉพาะเครื่อง ทั้งหมดไม่ใช่ซอร์สซอฟต์แวร์ที่จำเป็นต่อการรับช่วง โมเดลที่มีอยู่ในโฟลเดอร์โครงการถูกเก็บไว้กับชุดซอร์ส ส่วนโมเดลที่โค้ดดาวน์โหลดภายหลังต้องตรวจสิทธิ์และเตรียม cache แยกตามคู่มือพัฒนา

A.2 โครงสร้างข้อมูลทดสอบและสิทธิ์

`manifest.json` มี 25 รายการพร้อมชื่อไฟล์ กลุ่ม คำค้น ผู้สร้าง และแหล่งที่มา ภาพจากแหล่งออนไลน์มีรหัสสิทธิ์ by หรือ by-sa ตามที่บันทึกไว้ โดยข้อมูลนี้คงจากต้นฉบับ ไม่ใช่ผลตรวจใบอนุญาตใหม่ทุกภาพ ภาพ `emotion_6.jpg` ถูกระบุว่าเป็นภาพที่ผู้ใช้จัดหาและยังต้องตรวจสิทธิ์ก่อนเผยแพร่สาธารณะ

`credits.csv` สะท้อนบัญชีผู้สร้างและ URL ของทุกภาพ เพื่อให้ผู้รับช่วงตรวจรายละเอียดเวอร์ชันใบอนุญาตและคงเครดิตก่อนเผยแพร่ซ้ำ ชุดส่งมอบนี้ใช้เพื่อรับช่วงและตรวจงานโครงการ ไม่ได้สรุปว่าทรัพยากรบุคคลที่สามทุกชิ้นอนุญาตใช้เชิงพาณิชย์โดยไม่มีเงื่อนไข

A.3 บัญชีรายภาพ

สรุปสั้น: ชุดทดสอบมีภาพ 25 ภาพ แบ่งเป็น 4 กลุ่ม ทดสอบจริง 24 ภาพ ระบบตอบกลับสำเร็จ 21 ภาพ (ร้อยละ 87.5) ใช้เวลาเฉลี่ย 2.24 วินาทีต่อภาพ อีก 3 ภาพไม่ได้ผลเพราะใช้โควตา API หมด ไม่ใช่เพราะระบบตีความภาพผิด

วิธีอ่านตาราง: แต่ละช่องคือภาพหนึ่งภาพ เช่น แถว 0 คอลัมน์อารมณ์คือไฟล์ `emotion_0.jpg`

- **ตัวเลข** คือจำนวนวินาทีตั้งแต่ส่งภาพจนได้คำบรรยายกลับมา
- **✗ โควตา** คือบริการ Gemini ปฏิเสธคำขอเพราะเรียกใช้เกินโควตา (รหัส HTTP 429)
- **ไม่ได้ทดสอบ** คือภาพ `emotion_6.jpg` ที่ผู้ใช้ส่งมาเพิ่มหลังการทดสอบรอบนี้ จึงยังไม่มีผล

ตารางที่ A.2: เวลาที่ระบบใช้ตอบต่อภาพ (วินาที) แยกตามกลุ่มภาพ

ภาพที่	อารมณ์ (emotion)	ท่าทาง (body)	สภาพแวดล้อม (env)	ไม่เน้นบุคคล (nolabel)
0	2.5	2.1	2.2	2.2
1	2.0	1.9	2.3	2.4
2	2.0	2.1	3.1	1.9
3	2.1	2.4	2.6	✗ โควตา
4	1.8	3.2	1.9	✗ โควตา
5	2.1	2.4	1.9	✗ โควตา
6	ไม่ได้ทดสอบ			
ได้ผล	6 / 6	6 / 6	6 / 6	3 / 6
เฉลี่ย	2.08	2.35	2.33	2.17

ภาคผนวก B

ตัวอย่างข้อมูลและแนวทางตรวจซ้ำ

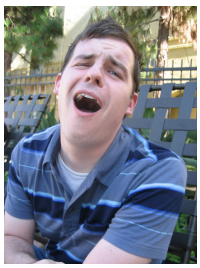
B.1 ตัวอย่างภาพทดสอบและสิ่งที่ระบบตอบ

ตารางนี้แสดงภาพตัวอย่าง 4 ภาพจากชุดทดสอบ พร้อมคำบรรยายที่ระบบสร้างจริงในไฟล์ `results.json` โดยไม่แก้ไขข้อความ ช่อง “คำค้น” คือคำที่ใช้ค้นหาภาพนั้นมา ซึ่งใช้เป็นสิ่งที่คาดหวังอย่างหยาบเท่านั้น

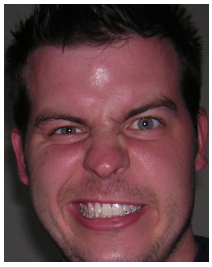
ตารางที่ B.1: ภาพตัวอย่าง คำบรรยายจากระบบ และเครดิตภาพ



`emotion_0.jpg` คำค้น: คนยิ้ม (smiling face portrait)
ระบบบรรยาย: หญิงสาวหน้าตายิ้มแย้มแจ่มใสดูมีความสุขมาก โดยมีจักรยานสีแดงที่บรรทุกสัมภาระจอดอยู่ด้านหลังในพื้นที่กลางแจ้ง
อารมณ์ที่ระบบระบุ: happy (มีความสุข) ความมั่นใจสูง
ตรงกับคำค้นหรือไม่: ตรง
เครดิตภาพ: “rachel smiling” โดย .jocelyn. สัญญาอนุญาต CC BY จาก Flickr



`emotion_1.jpg` คำค้น: คนร้องไห้ (crying person face)
ระบบบรรยาย: ชายหนุ่มสวมเสื้อโปโลลายขวางนั่งอยู่บนเก้าอี้เหล็กกลางแจ้ง เขากำลังอ้าปากกว้างและทำหน้าตาเหมือนคนกำลังหาวหรือจาม
อารมณ์ที่ระบบระบุ: neutral (เฉย ๆ) ความมั่นใจต่ำ
ตรงกับคำค้นหรือไม่: ไม่ตรง ต้องให้คนตรวจภาพจริงว่าคำค้นหรือระบบถูก
เครดิตภาพ: “My Oh Face” โดย greggoconnell สัญญาอนุญาต CC BY จาก Flickr



`emotion_2.jpg` คำค้น: คนโกรธ (angry face person)
ระบบบรรยาย: ชายคนหนึ่งกำลังทำหน้าตาโกรธจัดใส่กล้อง คิ้วขมวดแน่นจนหน้าผากย่นและจมูกย่นเข้าหากัน ดูเหมือนเขากำลังไม่พอใจอย่างมาก
อารมณ์ที่ระบบระบุ: angry (โกรธ) ความมั่นใจสูง
ตรงกับคำค้นหรือไม่: ตรง
เครดิตภาพ: “Angry @ The Terrorists” โดย greggoconnell สัญญาอนุญาต CC BY จาก Flickr



`env_0.jpg` คำค้น: ภายในร้านกาแฟ (coffee shop interior)
ระบบบรรยาย: ภายในร้านมีบรรยากาศคลาสสิก มีชายคนหนึ่งนั่งนิ่งอยู่บนเก้าอี้ไม้ และอีกคนนั่งหันหลังให้บนเก้าอี้สีแดงข้างตู้ลิ้นชักไม้ขนาดใหญ่ **คำเตือน:** พื้นที่ค่อนข้างแคบ อาจเดินชนตู้ได้ง่าย
อารมณ์ที่ระบบระบุ: neutral (เฉย ๆ) ความมั่นใจปานกลาง
ตรงกับคำค้นหรือไม่: ตรง
เครดิตภาพ: “Coffee beans for sale – Brother Baba Budan” โดย avlxyz สัญญาอนุญาต CC BY-SA จาก Flickr

URL เต็มของทุกภาพอยู่ใน `data/credits.csv` ภาพ 4 ภาพนี้เป็นเพียงตัวอย่าง ไม่ใช่ผลประเมินทั้งชุด

B.2 ข้อควรระวังในการรันทดสอบซ้ำ

สคริปต์ `eval/run.py` เขียนทับ `results.json` และ `score.csv` จึงต้องสำรองไฟล์หรือรันในสำเนาโครงการก่อน การรันยังเรียกบริการภายนอกและใช้โควตา API ต้องกำหนดชุดภาพและค่าทดลองให้แน่นอนก่อนเริ่ม ส่วนการสรุปไฟล์ผลเดิมสามารถทำโดยไม่ต้องเรียกโมเดลใหม่

B.3 ข้อมูลที่ยังต้องเติมก่อนรับรองการใช้งานจริง

ยังต้องจัดทำรายงานประเมินโดยมนุษย์ ผลทดสอบกับผู้ใช้เป้าหมาย บันทึกฮาร์ดแวร์และเวอร์ชัน dependency ที่ตรึงแล้ว ผลสอบเทียบระยะจริง และนโยบายข้อมูลสำหรับบริการที่นำไปใช้งาน ไม่ควรเติมข้อมูลเหล่านี้ย้อนหลังหากไม่มีหลักฐานการดำเนินการ